

Previsao de Satisfacao de Clientes

Olist Brazilian E-Commerce Dataset

Trabalho Final - Data Science
Universidade de Passo Fundo - UPF

Autor: **Murilo Moreira Mognon**

Repositorio: https://github.com/mognon-murilo/Trabalho_Final_DataScience__

2025

1. Introducao

O presente trabalho desenvolve um modelo de aprendizado de maquina para prever a satisfacao de clientes de e-commerce. O problema e formulado como **classificacao binaria**: dado um conjunto de informacoes sobre um pedido (prazo de entrega, valor, frete, categoria), o modelo deve prever se o cliente ficara **satisfeito** (nota ≥ 4) ou **insatisfeito** (nota ≤ 3). Identificar clientes insatisfeitos antecipadamente permite acoes proativas como reembolsos automaticos e contato preventivo, reduzindo churn e aumentando retencao.

Hipoteses iniciais

H1. Atraso na entrega e o principal fator de insatisfacao.

H2. Frete alto em relacao ao valor do pedido reduz a satisfacao.

H3. A categoria do produto influencia a expectativa e a avaliacao.

H4. Pedidos interestaduais tem mais atrasos e menor satisfacao.

H5. Pagamentos parcelados estao associados a piores avaliacoes.

2. Dataset

O dataset e o **Olist Brazilian E-Commerce Dataset** (<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>), com pedidos reais de 2016 a 2018 em 9 tabelas relacionais. Apos join: ~99.441 linhas. Apos limpeza: **86.811 linhas x 138 colunas**.

2.1 Dicionario de Variaveis

Variavel	Origem	Descricao
order_status	orders	Status do pedido (delivered, canceled...)
order_delivered_customer_date	orders	Data de entrega ao cliente
order_estimated_delivery_date	orders	Data estimada de entrega
price / freight_value	order_items	Preco unitario e frete por item
review_score	reviews	Nota de 1 a 5 - variavel-alvo
payment_type	payments	Tipo de pagamento (credit_card, boleto...)
payment_installments	payments	Numero de parcelas
customer_state / seller_state	clientes/vendedores	Estado do cliente e vendedor
product_category_name_english	products	Categoria do produto em ingles

2.2 Features Criadas

Feature	Descricao
delivery_delay_days	Dias entre entrega real e estimada (negativo = adiantado)
shipping_days	Dias entre aprovacao do pedido e envio ao transportador
estimated_delivery_days	Prazo estimado em dias no momento da compra
is_late	Flag: 1 se chegou apos a data estimada
freight_ratio	Proporcao do frete sobre o valor total do pedido
target	1 = satisfeito (score ≥ 4), 0 = insatisfeito (score ≤ 3)

2.3 Pre-processamento

1. Filtragem: apenas pedidos 'delivered' (unicos com review confiavel).
2. Remocao de nulos no target (review_score ausente).
3. Ausentes: mediana para numericas, 'unknown' para categoricas.
4. Outliers: IQR x 3,0 em price_total, freight_total, delivery_delay_days, payment_value.
5. Encoding: One-Hot com drop_first=True em payment_type, customer_state, seller_state, product_category.
6. Normalizacao: StandardScaler nas 11 features numericas.
7. Split: 80% treino (69.449) / 20% teste (17.362), estratificado.

3. Analise Exploratoria

Distribuicao da Variavel-alvo




Figura 1 - Distribuicao do target (esq.) e do review_score (dir.). Dataset desbalanceado: 79% satisfeitos / 21% insatisfeitos.

H1 - Atraso na entrega impacta negativamente a satisfacao




Figura 2 - Nota media por status de entrega (esq.) e distribuicao de delivery_delay_days por classe (dir.).

Pedidos com atraso tem nota media 2,4 vs 4,3 no prazo. 61% dos atrasados receberam nota ≤ 3 . **Hipotese confirmada** - is_late e delivery_delay_days sao as features mais importantes.

H2 - Frete alto reduz a satisfacao




Figura 3 - Freight ratio por classe (esq.) e scatter freight_ratio vs review_score (dir.).

Insatisfeitos tem mediana de freight_ratio maior. Pedidos com ratio > 0,3 tem insatisfacao 38% maior. **Hipotese parcialmente confirmada.**

H3 - Categoria do produto influencia a avaliacao




Figura 4 - Top 16 categorias por nota media (min. 200 pedidos).

Variacao significativa entre categorias (3,2 a 4,7). **Hipotese confirmada** - categoria incluida via One-Hot Encoding.

H4 - Pedidos interestaduais tem mais atrasos




Figura 5 - Taxa de atraso e nota media por tipo de rota.

Interestaduais: taxa de atraso 18% maior e nota 0,3 ponto abaixo. **Hipotese confirmada.**

H5 - Pagamento parcelado associado a piores avaliacoes




Figura 6 - Nota media e ticket mediano por faixa de parcelas.

Pedidos com 7+ parcelas: ticket 3,2x maior e nota 0,4 ponto abaixo da media. **Hipotese parcialmente confirmada.**

Estatisticas Descritivas

Feature	Media	Mediana	Desvio Padrao	Min	Max
review_score	4,09	5,00	1,32	1	5
delivery_delay_days	-10,8	-12,0	9,7	-92	52
shipping_days	2,6	2,0	2,1	0	30
freight_ratio	0,17	0,13	0,15	0,01	2,0
price_total	R\$121	R\$74	R\$183	R\$0,85	R\$6.735
payment_installments	2,9	1,0	3,2	1	24

Tabela 1 - Estatisticas descritivas das principais features numericas.

4. Modelagem

Todos os modelos foram implementados em **NumPy puro**, sem frameworks de ML no treinamento.

4.1 Regressao Logistica

Gradient descent com regularizacao L2 ($C=0,5$, $lr=0,05$, 200 epocas) e `class_weight='balanced'` para compensar o desbalanceamento 79/21%. **Justificativa:** modelo interpretavel e eficiente como baseline forte.

4.2 Naive Bayes Gaussiano

Likelihood gaussiana por feature, predicao via log-posteriors com softmax. **Justificativa:** baseline probabilistico classico para comparacao de desempenho.

4.3 Gradient Boosting com Decision Stumps

Algoritmo de Friedman (2001) com log-loss. Cada iteracao treina um stump sobre os residuos. Subsampling 50%, ate 12 features por stump, $n=100$, $lr=0,15$. **Justificativa:** estado da arte em dados tabulares, eficiente com stumps.

4.4 Validacao

Stratified 3-Fold Cross-Validation no treino + avaliacao final em holdout 20%. Metricas: Accuracy, F1-Score (macro), Precision, Recall, ROC-AUC.

5. Resultados e Discussao

Modelo	Accuracy	F1 (macro)	Precision	Recall	ROC-AUC
Regressao Logistica	0,7471	0,6290	0,6233	0,6347	0,6818
Naive Bayes Gaussiano	0,2240	0,2018	0,5147	0,3862	0,6469
Gradient Boosting	0,8292	0,6121	0,8167	0,5310	0,6633

Tabela 2 - Metricas no conjunto de teste (holdout 20%, 17.362 amostras). Linha verde = melhor acuracia.

O **Gradient Boosting** teve maior acuracia (82,9%) e precisao (81,7%) - quando prediz insatisfacao, acerta com alta confiabilidade, mas recall de 53% indica que perde parte dos casos. A **Regressao Logistica** teve melhor F1 macro (0,629) e ROC-AUC (0,6818), sendo mais equilibrada - preferivel quando o custo de falso negativo e alto. O **Naive Bayes** teve baixa acuracia por violar a suposicao de independencia (`is_late` e `delivery_delay_days` sao altamente correlacionadas), mas ROC-AUC de 0,647.

Feature Importances - Gradient Boosting

Feature	Importancia
<code>is_late</code>	33,5%
<code>delivery_delay_days</code>	27,0%
<code>shipping_days</code>	11,9%
<code>freight_ratio</code>	6,8%
<code>estimated_delivery_days</code>	4,3%
<code>price_total</code>	3,1%

Tabela 3 - Importancia de features no Gradient Boosting. Features de entrega = 72% do total.

6. Conclusao

O projeto demonstrou que e possivel prever a satisfacao de clientes de e-commerce com boa acuracia usando dados logísticos e de pagamento. O Gradient Boosting obteve acuracia de 82,9% e a Regressao Logistica foi mais robusta ao desbalanceamento (melhor F1 e ROC-AUC). O atraso na entrega e o principal determinante de insatisfacao, confirmando as hipoteses iniciais.

Limitacoes

Dataset cobre apenas 2016-2018. Desbalanceamento 79/21% exige atencao na interpretacao da acuracia. Comentarios textuais dos reviews nao foram utilizados. Sem hiperparametrizacao sistematica.

Trabalhos Futuros

Aplicar SMOTE para o desbalanceamento. Analise de sentimento nos comentarios via TF-IDF/BERT. Testar XGBoost, LightGBM e redes neurais. Monitoramento de data drift em producao.

7. Referencias

- [1] FRIEDMAN, J. H. Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*, v. 29, n. 5, p. 1189-1232, 2001.
- [2] OLIST. Brazilian E-Commerce Public Dataset. Kaggle, 2018.
<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>
- [3] HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning*. 2. ed. Springer, 2009.
- [4] MITCHELL, T. M. *Machine Learning*. McGraw-Hill, 1997.